

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



Báo cáo Bài tập lớn

Khai phá dữ liệu

Dự đoán doanh số bán hàng

Dựa trên dữ liệu lịch sử

GVHD: Thầy Bùi Tiến Đức
Sinh viên: Lê Võ Đăng Khoa 2211606

TP. Hồ Chí Minh, 10/2025



Contents

1	Danh sách hình ảnh và bảng biểu	3
2	Mô tả bài toán	4
2.1	Bối cảnh và vấn đề	4
2.2	Mô tả dữ liệu	4
2.3	Mục tiêu khai phá dữ liệu	5
3	Tiền xử lý dữ liệu	6
3.1	Tích hợp dữ liệu	6
3.2	Khám phá dữ liệu (Exploratory Data Analysis - EDA)	7
3.2.1	Thống kê mô tả (Descriptive Statistics)	7
3.2.2	Phân tích biến mục tiêu (Target Variable Analysis)	7
3.2.3	Phân tích tương quan (Correlation Analysis)	8
3.3	Các bước làm sạch và chuẩn bị dữ liệu	10
3.3.1	Xử lý giá trị thiếu (Missing Values)	10
3.3.2	Xử lý nhiễu và giá trị ngoại lệ (Noise/Outliers)	10
3.3.3	Chọn lọc thuộc tính (Feature Engineering & Selection)	11
3.3.4	Chuẩn hóa dữ liệu (Normalization)	14
3.4	Kết quả sau tiền xử lý	14
3.4.1	Thay đổi về cấu trúc và tính đầy đủ	14
3.4.2	Xử lý nhiễu (Từ log xử lý dữ liệu)	15
3.4.3	Tóm tắt trước và sau tiền xử lý	15
3.4.4	Kết luận	15
4	Áp dụng thuật toán	16
4.1	Lựa chọn Nhóm Thuật toán	16
4.1.1	Phân tích yêu cầu bài toán	16
4.1.2	Lý do lựa chọn Hồi quy (Regression)	16
4.1.3	Phân tích và loại trừ các nhóm thuật toán khác	16
4.1.4	Kết luận	17
4.2	Hồi quy tuyến tính (Linear Regression)	17
4.2.1	Giới thiệu	17
4.2.2	Lý do áp dụng	18
4.2.3	Kết quả (Tập kiểm tra)	18
4.2.4	Phân tích	18
4.3	Hồi quy Cây quyết định (Decision Tree Regression)	18
4.3.1	Giới thiệu	18
4.3.2	Lý do áp dụng	18
4.3.3	Kết quả (Tập kiểm tra)	18
4.3.4	Phân tích	19
4.4	Hồi quy Rừng ngẫu nhiên (Random Forest Regression)	19
4.4.1	Giới thiệu	19
4.4.2	Lý do áp dụng	19
4.4.3	Kết quả (Tập kiểm tra)	19
4.4.4	Phân tích	20
4.5	So sánh kết quả	20
4.5.1	Bảng so sánh hiệu suất	20
4.5.2	Trực quan hóa hiệu suất dự đoán	20



4.5.3	Phân tích Đường cong học tập (Learning Curve)	22
4.5.4	Kết luận chung	23
5	Giao diện người dùng	24
5.1	Giao diện tải tập dữ liệu	24
5.2	Giao diện khám phá dữ liệu (EDA)	25
5.3	Giao diện tiền xử lý dữ liệu	26
5.4	Giao diện cấu hình và huấn luyện mô hình	28
5.5	Giao diện chạy thử mô hình	29
6	Phân tích và Thảo luận kết quả	31
6.1	Phân tích ý nghĩa của kết quả	31
6.2	Hạn chế của mô hình	32
6.3	Hướng phát triển	32
7	Ràng buộc bổ sung	33
7.1	Đối thủ cạnh tranh	33
7.2	Sự kiện bất khả kháng (Thiên nga đen)	33
7.3	Thay đổi về luật/chính sách	34
8	Tài liệu tham khảo	35
9	Phụ lục	36
9.1	Mã nguồn	36
9.2	Nguồn dữ liệu	36

1 Danh sách hình ảnh và bảng biểu

List of Figures

3.1.1 Tích hợp dữ liệu	6
3.2.1 Phân phối của Doanh số hàng tuần (Weekly_Sales Distribution)	8
3.2.2 Biểu đồ nhiệt tương quan giữa các biến số	9
3.3.1 Tính thời vụ	11
3.3.2 Mối quan hệ giữa Weekly_Sales và Size	13
3.3.3 Mối quan hệ giữa Weekly_Sales và các Type	13
3.3.4 Tầm quan trọng của đặc trưng	14
4.5.1 Hiệu suất yếu kém của mô hình Linear Regression	21
4.5.2 Hiệu suất cải thiện của Decision Tree (có dấu hiệu overfitting)	21
4.5.3 Hiệu suất tối ưu của Random Forest	22
4.5.4 So sánh Đường cong học tập (Learning Curves)	22
5.1.1 Giao diện trước khi tải tập dữ liệu	24
5.1.2 Giao diện hiển thị dữ liệu thô và thông tin tổng quan	24
5.2.1 Tab hiển thị Biểu đồ nhiệt tương quan (Heatmap)	25
5.2.2 Tab hiển thị Xu hướng doanh số theo thời gian	25
5.3.1 Xử lý dữ liệu khuyết (Missing Values)	26
5.3.2 Tạo đặc trưng mới (Feature Engineering)	27
5.3.3 Chuẩn bị bộ chuẩn hóa (StandardScaler)	27
5.4.1 Chia tập dữ liệu và Cấu hình tham số (Hyperparameters)	28
5.4.2 Kết quả đánh giá mô hình (RMSE và R^2)	28
5.4.3 Biểu đồ phân tán Thực tế vs Dự đoán	29
5.5.1 Giao diện dự đoán doanh thu tùy chỉnh	29

List of Tables

2.2.1 Mô tả <code>stores.csv</code>	4
2.2.2 Mô tả tệp <code>features.csv</code>	5
2.2.3 Mô tả tệp <code>train.csv</code>	5
3.2.1 Thống kê mô tả các thuộc tính số	7
3.4.1 So sánh trạng thái dữ liệu trước và sau tiền xử lý	15
4.1.1 Phân tích các nhóm thuật toán và lý do loại trừ	17
4.5.1 So sánh hiệu suất giữa các thuật toán	20

2 Mô tả bài toán

2.1 Bối cảnh và vấn đề

Trong ngành bán lẻ, việc dự báo doanh số bán hàng là một trong những bài toán quan trọng và thách thức nhất. Đối với một tập đoàn quy mô toàn cầu như **Walmart**, việc dự báo chính xác có ảnh hưởng trực tiếp đến hiệu quả hoạt động kinh doanh.

Bối cảnh: Hoạt động của một chuỗi siêu thị bán lẻ phụ thuộc vào nhiều yếu tố biến động liên tục như: các ngày lễ trong năm, các chương trình khuyến mãi (*Markdown*), và các yếu tố kinh tế – xã hội bên ngoài (như giá nhiên liệu, tỷ lệ thất nghiệp).

Vấn đề:

- **Tối ưu tồn kho:** Nếu dự báo quá cao, Walmart sẽ bị tồn đọng hàng hóa, tăng chi phí lưu kho (đặc biệt với hàng hóa dễ hỏng). Ngược lại, nếu dự báo quá thấp, cửa hàng sẽ bị *thiếu hàng*, dẫn đến mất doanh thu và giảm sự hài lòng của khách hàng.
- **Quản lý nhân sự:** Dự báo doanh số giúp ban quản lý cửa hàng sắp xếp lịch làm việc và số lượng nhân viên phù hợp với lượng khách hàng dự kiến, tránh lãng phí chi phí nhân công hoặc thiếu người phục vụ.

Vì vậy, vấn đề đặt ra là cần xây dựng một mô hình dựa trên dữ liệu lịch sử để dự đoán doanh số bán hàng hàng tuần một cách chính xác, giúp Walmart đưa ra các quyết định kinh doanh hiệu quả hơn.

2.2 Mô tả dữ liệu

Nguồn dữ liệu: Bộ dữ liệu được sử dụng có tên “*Walmart Sales Forecast*”, được thu thập và công bố công khai trên nền tảng Kaggle (tại địa chỉ: <https://www.kaggle.com/datasets/aslanahmedov/walmart-sales-forecast>).

Mô tả dữ liệu: Bộ dữ liệu bao gồm thông tin bán hàng lịch sử của **45 cửa hàng Walmart** trong giai đoạn từ năm 2010 đến 2012. Dữ liệu được chia thành ba tập chính như sau:

Table 2.2.1: Mô tả `stores.csv`

Tên thuộc tính	Kiểu dữ liệu	Ý nghĩa
Store	Integer	Mã định danh của cửa hàng (từ 1 đến 45)
Type	String	Loại cửa hàng (A, B hoặc C)
Size	Integer	Diện tích của cửa hàng

Table 2.2.2: Mô tả tệp `features.csv`

Tên thuộc tính	Kiểu dữ liệu	Ý nghĩa
Store	Integer	Mã cửa hàng (khóa ngoại liên kết với <code>stores.csv</code>)
Date	Date	Ngày tháng năm
Temperature	Double	Nhiệt độ trung bình tại khu vực cửa hàng
Fuel_Price	Double	Giá nhiên liệu trung bình tại khu vực
MarkDown1-5	Double	Dữ liệu ẩn danh về 5 loại chương trình giảm giá (<i>MarkDown</i>). Giá trị NaN nghĩa là không có giảm giá.
CPI	Double	Chỉ số giá tiêu dùng
Unemployment	Double	Tỷ lệ thất nghiệp tại khu vực
IsHoliday	Boolean	Đánh dấu tuần đó có phải tuần lễ đặc biệt hay không

Table 2.2.3: Mô tả tệp `train.csv`

Tên thuộc tính	Kiểu dữ liệu	Ý nghĩa
Store	Integer	Mã cửa hàng
Dept	Integer	Mã định danh phòng ban (ví dụ: quần áo, điện tử, ...)
Date	Date	Ngày tháng năm
Weekly_Sales	Double	Biến mục tiêu (<i>Target Variable</i>) –Doanh số bán hàng trong tuần
IsHoliday	Boolean	Đánh dấu tuần lễ đặc biệt

2.3 Mục tiêu khai phá dữ liệu

Dựa trên bối cảnh và bộ dữ liệu được cung cấp, các mục tiêu khai phá dữ liệu của nhóm được xác định như sau:

Mục tiêu chính: Xây dựng một mô hình có khả năng dự đoán tương đối chính xác giá trị `Weekly_Sales` (doanh số hàng tuần) cho từng phòng ban tại từng cửa hàng.

Mục tiêu phụ:

- Thực hiện phân tích khám phá dữ liệu để hiểu rõ đặc điểm của dữ liệu và mối quan hệ giữa các biến (ví dụ: doanh số tăng hay giảm vào ngày lễ? Nhiệt độ ảnh hưởng đến doanh số ra sao?).
- Phân tích và xác định các yếu tố (*features*) có ảnh hưởng quan trọng nhất đến doanh số bán hàng.
- Sử dụng và đánh giá một vài thuật toán Data Mining khác nhau để tìm ra mô hình có kết quả dự đoán tốt nhất.

3 Tiền xử lý dữ liệu

3.1 Tích hợp dữ liệu

Dữ liệu ban đầu được phân tách thành ba tệp: **train.csv** (chứa dữ liệu doanh số theo phòng ban), **features.csv** (chứa dữ liệu đặc trưng theo tuần của cửa hàng), và **stores.csv** (chứa thông tin mô tả cửa hàng).

Để chuẩn bị cho việc phân tích, nhóm đã tiến hành gộp ba tệp này thành một **DataFrame** duy nhất (**df**) bằng cách sử dụng phương thức **merge** của thư viện **Pandas**, dựa trên các khóa chung như sau:




Figure 3.1.1: Tích hợp dữ liệu

- **Gộp train.csv với features.csv:**

- **Loại gộp:** Sử dụng *Left Join* (`how="left"`), với **train.csv** là bảng bên trái.
- **Khóa (Keys):** Gộp trên bộ khóa gồm 3 cột: `["Store", "Date", "IsHoliday"]`. Việc này đảm bảo mỗi bản ghi doanh số của từng phòng ban được ánh xạ chính xác với các đặc điểm của cửa hàng vào đúng ngày tương ứng.

- **Gộp kết quả với stores.csv:**

- **Loại gộp:** Tiếp tục sử dụng *Left Join* (`how="left"`).
- **Khóa (Key):** Gộp trên cột `["Store"]`.
- **Mục đích:** Thêm thông tin về loại cửa hàng (**Type**) và kích thước (**Size**) vào từng bản ghi.

Kết quả: Quá trình này tạo ra một **DataFrame** duy nhất, thống nhất chứa **421.570 bản ghi**. **DataFrame** này bảo toàn tất cả các mẫu trong tệp **train.csv** gốc và được làm giàu thêm các đặc trưng từ hai tệp **features.csv** và **stores.csv**, sẵn sàng cho bước **Khám phá Dữ liệu (EDA)**.

3.2 Khám phá dữ liệu (Exploratory Data Analysis - EDA)

Giai đoạn EDA được thực hiện với mục tiêu tìm hiểu cấu trúc, phân phối và các mối quan hệ bên trong bộ dữ liệu. Nhóm đã sử dụng thư viện **Pandas** để tải và tính toán thống kê, cùng với thư viện **Seaborn** và **Matplotlib** để trực quan hóa.

3.2.1 Thống kê mô tả (Descriptive Statistics)

Sau khi tải và gộp dữ liệu, nhóm thực hiện hàm `.describe()` trên các cột dữ liệu số để có cái nhìn tổng quan đầu tiên.

Table 3.2.1: Thống kê mô tả các thuộc tính số

Thuộc tính	Count	Mean	Std	Min	25%	50% (Median)	75%	Max
Store	421570	22.20	12.79	1.00	11.00	22.00	33.00	45.00
Dept	421570	44.26	30.49	1.00	18.00	37.00	74.00	99.00
Weekly_Sales	421570	15981.26	22711.18	-4988.94	2079.65	7612.03	20205.85	693099.36
Temperature	421570	60.09	18.45	-2.06	46.68	62.09	74.28	100.14
Fuel_Price	421570	3.36	0.46	2.47	2.93	3.45	3.74	4.47
MarkDown1	150681	7246.42	8291.22	0.27	2240.27	5347.45	9210.90	88646.76
MarkDown2	111248	3334.63	9475.36	-265.76	41.60	192.00	1926.94	104519.54
MarkDown3	137091	1439.42	9623.08	-29.10	5.08	24.60	103.99	141630.61
MarkDown4	134967	3383.17	6292.38	0.22	504.22	1481.31	3595.04	67474.85
MarkDown5	151432	4628.98	5962.89	135.16	1878.44	3359.45	5563.80	108519.28
CPI	421570	171.20	39.16	126.06	132.02	182.32	212.42	227.23
Unemployment	421570	7.96	1.86	3.88	6.89	7.87	8.57	14.31
Size	421570	136727.92	60980.58	34875	93638	140167	202505	219622

Nhận xét **Weekly_Sales** từ Bảng 3.1.1:

- **Giá trị *Min* là số âm (~-4960.94):** có thể đại diện cho các giao dịch bị trả hàng (*refunds*) hoặc lỗi nhập liệu. Đây là một vấn đề cần xử lý trong bước làm sạch dữ liệu.
- **Trung bình (mean) là 15,981 và trung vị (med): 7,612:** Giá trị trung bình lớn hơn đáng kể so với giá trị trung vị. Điều này cho thấy dữ liệu bị lệch phải (*right-skewed*).

3.2.2 Phân tích biến mục tiêu (Target Variable Analysis)

Biến mục tiêu của bài toán là **Weekly_Sales**. Việc hiểu rõ phân phối của nó là điều bắt buộc. Nhóm đã sử dụng biểu đồ phân phối (*Histogram*) để trực quan hóa.




Figure 3.2.1: Phân phối của Doanh số hàng tuần (Weekly_Sales Distribution)

Phân tích Hình 3.1.1:

- Biểu đồ này xác nhận một cách trực quan những gì chúng ta thấy trong `.describe()`
- **Phân phối lệch:** Biểu đồ cho thấy rõ ràng rằng `Weekly_Sales` không tuân theo phân phối chuẩn mà bị **lệch phải (right-skewed)** rất mạnh. Điều này có nghĩa là phần lớn doanh số hàng tuần ở mức thấp đến trung bình, và chỉ một số ít tuần có doanh số cực cao (tạo thành "đuôi phải").
- **Giá trị âm:** Quan sát ở phía bên trái trục 0 có một nhóm nhỏ dữ liệu âm, xác nhận các giá trị âm trong Bảng 3.1.1.
- **Ý nghĩa:** Phần lớn các quan sát (doanh số hàng tuần của một phòng ban) có giá trị tương đối thấp (khoảng 0 - 50,000), nhưng có một số ít trường hợp có doanh số rất cao (các giá trị ngoại lệ - outliers) kéo giá trị trung bình lên. Những ngoại lệ này có thể là các tuần lễ hội lớn (Black Friday, Giáng sinh).

3.2.3 Phân tích tương quan (Correlation Analysis)

Để hiểu mối quan hệ tuyến tính giữa các biến số, nhóm đã tính toán **ma trận tương quan (correlation matrix)** và trực quan hóa bằng **biểu đồ nhiệt (heatmap)**.




Figure 3.2.2: Biểu đồ nhiệt tương quan giữa các biến số

Phân tích Hình 3.1.2:

- Biểu đồ nhiệt hiển thị hệ số tương quan Pearson:
 - Giá trị gần +1.0 (màu đỏ đậm): tương quan đồng biến mạnh (X tăng thì Y tăng).
 - Giá trị gần -1.0 (màu xanh đậm): tương quan nghịch biến mạnh (X tăng thì Y giảm).
 - Giá trị gần 0: ít hoặc không có tương quan tuyến tính.
- Phát hiện quan trọng về **Weekly_Sales**:
 - **Hàng Weekly_Sales**: đa số các ô (so với các biến số khác như **Temperature**, **Fuel_Price**, **CPI**, **Unemployment**, và các **Markdown**) đều có màu rất nhạt, và các con số đều rất gần 0 (ví dụ: -0.00, 0.00, 0.09, -0.02, -0.03).
 - **Kích thước Cửa hàng (Size)**: là yếu tố có ảnh hưởng tuyến tính **MẠNH NHẤT**, nhưng vẫn chỉ ở mức yếu (+0.24).
 - **Tuy nhiên**: Điều này **KHÔNG** có nghĩa là chúng không quan trọng. Nó chỉ có nghĩa là một mô hình tuyến tính đơn giản (ví dụ: $\text{Sales} = A \times \text{Temperature} + B$) sẽ không hoạt động tốt. Mỗi quan hệ có thể phức tạp hơn (phi tuyến tính).
- **Phát hiện thú vị khác**: **Markdown1** và **Markdown4** có tương quan dương rất mạnh ($r \approx +0.85$), cho thấy hai chương trình khuyến mãi này thường được tung ra cùng lúc. Hiện tượng này cần được lưu ý vì có thể ảnh hưởng đến độ ổn định của các mô hình hồi quy.

3.3 Các bước làm sạch và chuẩn bị dữ liệu

3.3.1 Xử lý giá trị thiếu (Missing Values)

Phát hiện ban đầu: Từ kết quả `df.info()`, tập dữ liệu có 421,570 bản ghi. Tuy nhiên, các cột `MarkDown1` - `MarkDown5` có số lượng giá trị `non-null` thấp hơn đáng kể:

- `MarkDown1`: 150,681 (thiếu ~64.2%)
- `MarkDown2`: 111,248 (thiếu ~73.6%)
- `MarkDown3`: 137,091 (thiếu ~67.5%)
- `MarkDown4`: 134,967 (thiếu ~68.0%)
- `MarkDown5`: 151,432 (thiếu ~64.1%)

Hành động: Điền giá trị 0 vào các cột `MarkDown` bị thiếu.

Lý do: Trong bối cảnh bán lẻ, giá trị thiếu ở các cột giảm giá (`MarkDown`) không nhất thiết là lỗi, mà thường đại diện cho trường hợp "không có chương trình giảm giá". Do đó, việc thay thế các giá trị thiếu bằng 0 (tương đương không giảm giá) là hợp lý và nhất quán về mặt nghiệp vụ.

3.3.2 Xử lý nhiễu và giá trị ngoại lệ (Noise/Outliers)

Phát hiện ban đầu:

- Kết quả `df.describe()` cho thấy giá trị tối thiểu của `Weekly_Sales` là -4988.94, một bất thường nghiêm trọng.
- Phát hiện 1,285 bản ghi có `Weekly_Sales < 0`.

Hành động: Đã xử lý bằng cách gán các giá trị âm thành 0.

Lý do:

- **Nguyên nhân khả dĩ:**
 - Lỗi nhập liệu (data entry error).
 - Doanh thu ròng (Net Sales) có thể bị âm nếu số hàng trả lại vượt quá hàng bán ra.
- **Tại sao không xoá dữ liệu:** Xoá 1,285 hàng (0.3%) sẽ làm mất thông tin quý giá khác.
- **Tại sao không lấy giá trị tuyệt đối:** Dễ gây sai lệch vì biến âm thành dương.
- **Giải pháp chọn:** Chuyển giá trị âm thành 0 là hợp lý nhất, xem như "không có doanh thu".
- **Biện luận:** Để tập trung vào dự báo nhu cầu mua sắm thay vì dòng tiền kế toán, quyết định đưa các giá trị âm về 0 để mô hình không bị nhiễu bởi các giao dịch hoàn trả phức tạp.

Kỹ thuật áp dụng: Đây là một kỹ thuật *Outlier Handling* dạng **Flooring/Capping** - chặn các giá trị vượt ngoài ngưỡng hợp lý (ở đây là nhỏ hơn 0) về giá trị biên hợp lệ.

3.3.3 Chọn lọc thuộc tính (Feature Engineering & Selection)

Feature Engineering (Tạo đặc trưng):

Phát hiện ban đầu: Cột `Type` có kiểu `object`, cột `Date` có kiểu `object` và `IsHoliday` có kiểu `bool`. Các mô hình học máy không thể xử lý trực tiếp các kiểu dữ liệu này.

Hành động: Tạo các đặc trưng mới:

- `Year`, `Month`, `WeekOfYear`, `Day`
- Chuyển `IsHoliday` từ `True/False` sang `1/0`.
- Tạo 3 cột `Type_A`, `Type_B`, `Type_C` và cho chúng kiểu `1/0` dựa theo `Type`.

Lý do:

- **Xu hướng (Trend):** Cột `Year` giúp mô hình nhận biết sự thay đổi doanh số qua các năm.
- **Tính thời vụ (Seasonality):** `Month` và `WeekOfYear` hỗ trợ mô hình học chu kỳ bán hàng.




Figure 3.3.1: Tính thời vụ

- **Mã hóa biến Phân loại bằng One-Hot Encoding:** cho phép mô hình (đặc biệt là Linear Regression) gán một **trọng số (hệ số) riêng biệt** cho từng loại mà không tạo ra bất kỳ một "thứ tự" giả mạo nào

Feature Selection (Lựa chọn đặc trưng):

Hành động: Sử dụng `SelectKBest` với hàm `f_regression` để đánh giá tầm quan trọng của từng đặc trưng trong việc dự đoán `Weekly_Sales`.

Kết quả:



Đặc trưng	Điểm (Score)
Size	26647.905144
Type_A	15009.499841
Dept	9445.215074
Type_B	7385.855222
Type_C	3871.207762
Store	3082.286020
MarkDown5	1076.346995
MarkDown1	940.157460
MarkDown3	627.806676
MarkDown4	592.619310
Month	340.566300
WeekOfYear	323.135235
Unemployment	282.117400
CPI	184.627819
MarkDown2	181.034378
IsHoliday	68.811742
Year	43.114262
Day	16.140026
Temperature	2.254012
Fuel_Price	0.006127

Nhận xét:

- **Quan trọng nhất:** Các đặc trưng **Size** (kích thước), **Type** (loại cửa hàng), và **Dept** (phòng ban) có điểm số cao vượt trội so với phần còn lại. Điều này khẳng định yếu tố quan trọng nhất để dự đoán doanh số là "đó là cửa hàng nào" và "phòng ban nào".
- **Không quan trọng:** **Fuel_Price** (giá xăng) và **Temperature** (nhiệt độ) có điểm số gần như bằng 0. Điều này xác nhận chúng gần như không có ảnh hưởng (một cách tuyến tính), hoàn toàn phù hợp với kết quả từ biểu đồ tương quan.




Figure 3.3.2: Mối quan hệ giữa Weekly_Sales và Size




Figure 3.3.3: Mối quan hệ giữa Weekly_Sales và các Type




Figure 3.3.4: Tầm quan trọng của đặc trưng

3.3.4 Chuẩn hóa dữ liệu (Normalization)

Chiến lược: Áp dụng `StandardScaler` để chuẩn hóa các cột số: `Temperature`, `Fuel_Price`, `CPI`, `Size`, `Unemployment`, và các cột `MarkDown`.

Quy trình thực hiện: Để đảm bảo tính khách quan và tránh hiện tượng Rò rỉ dữ liệu (Data Leakage), việc chuẩn hóa sẽ không được thực hiện ngay trên toàn bộ tập dữ liệu gốc. Thay vào đó, quy trình sẽ là:

- Giữ nguyên dữ liệu thô ở bước này.
- Khởi tạo đối tượng `Scaler`.
- Việc tính toán tham số (fit) và biến đổi (transform) sẽ được thực hiện sau khi dữ liệu đã được chia tách thành tập Huấn luyện (Train) và Kiểm tra (Test).

3.4 Kết quả sau tiền xử lý

3.4.1 Thay đổi về cấu trúc và tính đầy đủ

- **Tính toàn vẹn dữ liệu:** Tổng số bản ghi vẫn là 421,570, cho thấy không có hàng nào bị xóa trong quá trình làm sạch.
- **Xử lý giá trị thiếu:** Tất cả 21 cột hiện tại đều có 421,570 giá trị non-null. Điều này xác nhận rằng 5 cột `MarkDown1-5` đã được điền đầy đủ bằng giá trị 0.
- **Feature Engineering:**

- Tổng số cột tăng từ 16 lên 21 cột.
 - Cột `Date` và `Type` (kiểu `object`) đã bị loại bỏ.
 - Các đặc trưng thời gian mới được tạo ra: `Year`, `Month`, `Day`, `WeekOfYear`, `Type_A`, `Type_B`, `Type_C`.
 - Cột `IsHoliday` (trước đây là `bool`) đã được chuyển đổi thành kiểu `int64` (0 hoặc 1).
- **Kiểu dữ liệu:** Tập dữ liệu cuối cùng gồm 11 cột `float`, 10 cột `int` —tất cả đều là định dạng số mà mô hình học máy có thể đọc được.

3.4.2 Xử lý nhiễu (Từ log xử lý dữ liệu)

- Log xác nhận rằng 1,285 bản ghi `Weekly_Sales` âm đã được phát hiện và xử lý.
- Không có hàng nào bị xóa, xác nhận rằng chiến lược flooring các giá trị âm về 0 đã được thực hiện thành công.
- Điều này giúp bảo toàn dữ liệu mà vẫn đảm bảo tính logic cho biến mục tiêu.

3.4.3 Tóm tắt trước và sau tiền xử lý

Table 3.4.1: So sánh trạng thái dữ liệu trước và sau tiền xử lý

Đặc điểm	Trước tiền xử lý	Sau tiền xử lý
Tổng số cột	16	21
Giá trị Null	Có (ở 5 cột Markdown)	Không
Cột <code>Date</code>	<code>object</code> (chuỗi)	Bị loại bỏ, thay bằng <code>Year</code> , <code>Month</code> , <code>WeekOfYear</code> , <code>Day</code>
Cột <code>Type</code>	<code>object</code> (chuỗi)	Bị loại bỏ, thay bằng <code>Type_A</code> , <code>Type_B</code> , <code>Type_C</code>
Cột <code>IsHoliday</code>	<code>bool</code> (<code>True/False</code>)	<code>int</code> (1/0)
Giá trị âm <code>Weekly_Sales</code>	Có (1,285 bản ghi)	Không (<code>min = 0</code>)

3.4.4 Kết luận

Tập dữ liệu đã hiện đã hoàn toàn sạch (không còn giá trị thiếu hay nhiễu) và có cấu trúc phù hợp (đã trích xuất đặc trưng số). Nó đã sẵn sàng cho bước tiếp theo là **phân chia dữ liệu** (**train/test split**) và đưa vào các mô hình học máy để huấn luyện.

4 Áp dụng thuật toán

Sau khi dữ liệu đã được làm sạch, tiền xử lý, bước tiếp theo là lựa chọn và áp dụng các thuật toán học máy phù hợp để xây dựng mô hình dự đoán.

4.1 Lựa chọn Nhóm Thuật toán

4.1.1 Phân tích yêu cầu bài toán

Mục tiêu cốt lõi của dự án này là **dự đoán giá trị của biến `Weekly_Sales` (Doanh số hàng tuần)**.

Từ quá trình Khám phá Dữ liệu (EDA) và Tiền xử lý, ta xác định:

- **Biến mục tiêu (Target Variable):** `Weekly_Sales`
- **Bản chất của biến:** Đây là một *giá trị số liên tục* (continuous), không phải là nhãn hoặc danh mục.
- Giá trị có thể là bất kỳ số thực dương nào: ví dụ 15981.25, 2079.65, v.v.

Do đó, bài toán đặt ra câu hỏi:

“Doanh số tuần tới sẽ là bao nhiêu?”

4.1.2 Lý do lựa chọn Hồi quy (Regression)

Dựa trên bản chất của biến mục tiêu, nhóm thuật toán phù hợp để giải quyết bài toán này là **Hồi quy (Regression)**.

Hồi quy là một lớp các thuật toán học máy có giám sát (*Supervised Learning*) được thiết kế để dự đoán một giá trị đầu ra **liên tục**. Mục tiêu của mô hình hồi quy là học một hàm toán học f từ các đặc trưng đầu vào X (ví dụ: `Store`, `Dept`, `Temperature`, `IsHoliday`) để ánh xạ đến giá trị đầu ra y (tức là `Weekly_Sales`) sao cho:

$$y \approx f(X)$$

Nói cách khác, mô hình sẽ cố gắng tìm ra một *đường thẳng* biểu diễn mối quan hệ giữa các yếu tố đầu vào và doanh số.

4.1.3 Phân tích và loại trừ các nhóm thuật toán khác

Để làm rõ hơn lý do lựa chọn Hồi quy, bảng dưới đây trình bày sự khác biệt giữa các nhóm thuật toán phổ biến và lý do tại sao chúng không phù hợp với bài toán này:

Table 4.1.1: Phân tích các nhóm thuật toán và lý do loại trừ

Nhóm toán	Thuật	Mục đích chính	Vì sao không phù hợp với bài toán này?
Classification (Phân loại)		Dự đoán một nhãn hoặc danh mục rời rạc (ví dụ: “Email là Spam/Không Spam”, “Doanh thu là Cao/Thấp”).	Mục tiêu của chúng ta là dự đoán một <i>giá trị số chính xác</i> (ví dụ: \$15,981), không phải một nhãn. Việc ép <code>Weekly_Sales</code> thành nhãn sẽ làm mất nhiều thông tin liên tục.
Clustering (Phân cụm)		Gom nhóm các điểm dữ liệu tương đồng mà không cần nhãn (học không giám sát).	Bài toán này có biến mục tiêu rõ ràng là <code>Weekly_Sales</code> . Đây là một bài toán học có giám sát, nên không thể dùng phân cụm.
Association Rules (Luật kết hợp)		Tìm các quy tắc đồng xuất hiện (ví dụ: “Nếu mua Sữa thì thường mua Bánh mì”).	Kỹ thuật này dùng để tìm mối quan hệ giữa các đặc trưng, không dùng để dự đoán một giá trị số.

4.1.4 Kết luận

Từ phân tích trên, có thể kết luận rằng:

- Bản chất của bài toán là dự đoán một **biến liên tục**.
- Do đó, nhóm thuật toán **Hồi quy (Regression)** là lựa chọn phù hợp nhất và duy nhất.
- Các bước tiếp theo sẽ tập trung vào việc lựa chọn và đánh giá các thuật toán cụ thể trong nhóm Hồi quy, ví dụ:
 - Linear Regression
 - Ridge / Lasso Regression
 - Decision Tree Regression
 - Gradient Boosting / XGBoost / LightGBM
 - Random Forest Regressor
 - Neural Network (MLP Regressor)

4.2 Hồi quy tuyến tính (Linear Regression)

4.2.1 Giới thiệu

Hồi quy tuyến tính (Linear Regression) là một thuật toán cơ bản, giả định rằng có một mối quan hệ tuyến tính giữa các đặc trưng đầu vào (ví dụ: `Temperature`, `CPI`) và biến mục tiêu (`Weekly_Sales`). Mô hình này cố gắng tìm ra phương trình đường thẳng phù hợp nhất để dự đoán y từ X :

$$y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \epsilon \quad (1)$$

4.2.2 Lý do áp dụng

Linear Regression được áp dụng chủ yếu như một mô hình cơ sở (*baseline model*). Đây là mô hình đơn giản, dễ huấn luyện và cung cấp điểm chuẩn cho việc đánh giá các mô hình phức tạp hơn. Mọi mô hình sau này đều cần chứng minh rằng hiệu quả vượt trội hơn mô hình tuyến tính cơ bản này.

4.2.3 Kết quả (Tập kiểm tra)

Sau khi huấn luyện trên **337,256 mẫu** và kiểm tra trên **84,314 mẫu**, kết quả thu được:

- R-squared (R^2): **0.0926**
- MAE (Lỗi tuyệt đối trung bình): **\$14,561.79**
- RMSE (Lỗi toàn phương trung bình): **\$21,752.04**

4.2.4 Phân tích

- **$R^2 = 0.0926$:** Mô hình chỉ giải thích được 9.26% sự biến động của `Weekly_Sales`, tức là hầu như không có quan hệ tuyến tính giữa đặc trưng và mục tiêu.
- **Sai số lớn:** MAE ở mức \$14,500 trong khi trung vị doanh số chỉ khoảng \$7,612. Điều này cho thấy độ sai lệch rất cao.

Kết luận: Hồi quy tuyến tính không phù hợp với bộ dữ liệu này.

4.3 Hồi quy Cây quyết định (Decision Tree Regression)

4.3.1 Giới thiệu

Hồi quy Cây quyết định (Decision Tree Regression) là một mô hình phi tham số, hoạt động bằng cách chia dữ liệu thành các tập con nhỏ dựa trên các quy tắc *if-then-else*. Mục tiêu là chia dữ liệu sao cho các mẫu trong cùng một “lá” (*leaf node*) có giá trị `Weekly_Sales` gần nhau nhất.

4.3.2 Lý do áp dụng

Decision Tree được chọn vì những lý do sau:

- **Nắm bắt quan hệ phi tuyến tính:** Không giống Linear Regression, mô hình này có thể học được mối quan hệ phức tạp giữa các đặc trưng.
- **Tự động học quy tắc kết hợp:** Ví dụ, “Nếu `Store = 1` và `IsHoliday = 1` thì `Weekly_Sales` tăng mạnh.”
- **Nhược điểm:** Dễ bị *overfitting* (học vẹt) nếu cây quá sâu.

4.3.3 Kết quả (Tập kiểm tra)

- R-squared (R^2): **0.9617**
- MAE (Lỗi tuyệt đối trung bình): **\$1,766.13**
- RMSE (Lỗi toàn phương trung bình): **\$5,568.92**

4.3.4 Phân tích

- **Hiệu suất vượt trội:** R^2 đạt 96,17%, mô hình đã học được phần lớn quy luật ẩn trong dữ liệu.
- **Sai số giảm mạnh:**
 - MAE giảm từ \$14,561 xuống \$1,766 (giảm 88%)
 - RMSE giảm từ \$21,752 xuống \$4,466 (giảm 79%)
- **Kết luận:** Decision Tree rất phù hợp với bài toán dự đoán doanh số, xác nhận rằng mối quan hệ giữa các đặc trưng là phi tuyến tính.

4.4 Hồi quy Rừng ngẫu nhiên (Random Forest Regression)

4.4.1 Giới thiệu

Random Forest là một thuật toán học máy Ensemble (Kết hợp). Thay vì chỉ xây dựng một Cây quyết định (Decision Tree) duy nhất, nó xây dựng một "khu rừng" gồm hàng trăm cây (trong trường hợp của chúng ta là 100 cây).

Nguyên lý hoạt động:

- **Bagging (Bootstrap Aggregating):** Mỗi cây trong rừng được huấn luyện trên một mẫu dữ liệu ngẫu nhiên (có lặp lại) từ tập huấn luyện.
- **Random Feature:** Tại mỗi nút của cây, thay vì xem xét tất cả các đặc trưng, cây chỉ được phép chọn ngẫu nhiên từ một tập con các đặc trưng.
- **Bỏ phiếu (Averaging):** Đối với bài toán Hồi quy, dự đoán cuối cùng của Random Forest là giá trị **trung bình** của dự đoán từ tất cả 100 cây.

4.4.2 Lý do áp dụng

Chúng ta đã thấy Decision Tree ($R^2=0.9617$) hoạt động rất tốt, nhưng nó có một điểm yếu chí mạng là overfitting (học vẹt). Một cây quyết định đơn lẻ sẽ cố gắng học thuộc lòng mọi chi tiết trong dữ liệu huấn luyện, bao gồm cả nhiễu, dẫn đến việc dự đoán kém trên dữ liệu mới.

Random Forest là giải pháp trực tiếp cho vấn đề này:

- **Chống Overfitting:** Bằng cách lấy trung bình dự đoán của 100 cây (mỗi cây hơi khác nhau một chút), các lỗi và "sự học vẹt" ngẫu nhiên của từng cây sẽ tự triệt tiêu lẫn nhau.
- **Tính ổn định (Robustness):** Mô hình cuối cùng trở nên ổn định và có khả năng **tổng quát hóa (generalize)** tốt hơn trên dữ liệu mà nó chưa từng thấy (tập test).
- **Độ chính xác cao:** Đây là một trong những thuật toán "tiêu chuẩn vàng" trong học máy, thường xuyên cho độ chính xác cao mà không cần tinh chỉnh quá nhiều.

4.4.3 Kết quả (Tập kiểm tra)

- R-squared (R^2): **0.9778**
- MAE (Lỗi tuyệt đối trung bình): **\$1,330.80**
- RMSE (Lỗi toàn phương trung bình): **\$3,404.74**

4.4.4 Phân tích

- **So sánh với Decision Tree:** R^2 đã tăng từ 0.9617 lên 0.9778. Quan trọng hơn, chỉ số lỗi MAE/RMSE đã giảm từ 1,766/4,466 xuống còn 1,330/3,404.
- **Ý nghĩa:** Điều này cho thấy Random Forest không chỉ giữ được khả năng nắm bắt các quy luật phi tuyến tính phức tạp của Decision Tree, mà còn cải thiện nó bằng cách giảm nhiễu và tạo ra các dự đoán chính xác hơn.
- **Kết luận:** Random Forest là mô hình vượt trội, cân bằng được giữa độ chính xác cao và khả năng chống overfitting, khiến nó trở thành mô hình tốt nhất trong ba mô hình chúng ta đã thử nghiệm.

4.5 So sánh kết quả

4.5.1 Bảng so sánh hiệu suất

Table 4.5.1: So sánh hiệu suất giữa các thuật toán

Chỉ số (Metric)	Linear Regression (Cơ sở)	Decision Tree Regression (Bị Overfitting)	Random Forest Regression (Mô hình tối ưu)
R-squared (R^2)	0.0926	0.9617	0.9778
MAE	\$14,561.79	\$1,766.13	\$1,330.80

4.5.2 Trực quan hóa hiệu suất dự đoán

Việc phân tích biểu đồ giúp ta hiểu sâu hơn về hành vi của từng mô hình vượt ra ngoài các con số thống kê.

- **Linear Regression (Mô hình tuyến tính):** Như quan sát trong Hình 4.5.1, mô hình thất bại hoàn toàn trong việc nắm bắt xu hướng dữ liệu. Biểu đồ phân tán (Hình 4.5.1a) cho thấy các điểm dự đoán nằm rất xa đường lý tưởng màu đỏ. Biểu đồ phần dư (Hình 4.5.1b) cho thấy lỗi có cấu trúc rõ ràng (không ngẫu nhiên), khẳng định giả định tuyến tính là sai lầm.




Figure 4.5.1: Hiệu suất yếu kém của mô hình Linear Regression

- **Decision Tree (Cây quyết định):** Hình 4.5.2 cho thấy sự cải thiện đáng kể. Các điểm dự đoán đã bám sát đường thực tế hơn rất nhiều. Tuy nhiên, biểu đồ phần dư vẫn còn một số điểm ngoại lệ lớn, dấu hiệu của việc mô hình có thể đang cố học các nhiễu trong dữ liệu huấn luyện.






Figure 4.5.2: Hiệu suất cải thiện của Decision Tree (có dấu hiệu overfitting)

- **Random Forest (Rừng ngẫu nhiên):** Đây là mô hình tối ưu nhất (Hình 4.5.3). Biểu đồ thực tế vs. dự đoán cho thấy sự tập trung dày đặc quanh đường lý tưởng. Quan trọng

nhất, biểu đồ phần dư cho thấy các lỗi được phân bố ngẫu nhiên hơn và tập trung rất sát quanh trục 0, chứng tỏ mô hình đã loại bỏ nhiều hiệu quả.



(a) Thực tế vs. Dự đoán




(b) Phân bố phần dư (Residuals)


Figure 4.5.3: Hiệu suất tối ưu của Random Forest

4.5.3 Phân tích Đường cong học tập (Learning Curve)

Để hiểu rõ hơn về vấn đề Underfitting (chưa học đủ) và Overfitting (học vẹt), chúng ta xem xét đường cong học tập của mô hình tệ nhất và tốt nhất.



(a) Linear Regression: Dấu hiệu High Bias (Underfitting)



(b) Random Forest: Cân bằng tốt Bias-Variance

Figure 4.5.4: So sánh Đường cong học tập (Learning Curves)

Nhận xét:

- **Linear Regression:** Cả điểm huấn luyện (Training score) và điểm kiểm tra (Validation score) đều hội tụ ở mức rất thấp (lỗi cao). Khoảng cách giữa hai đường rất nhỏ. Đây là

đặc điểm điển hình của **Underfitting (High Bias)** - mô hình quá đơn giản để nắm bắt dữ liệu.

- **Random Forest:** Điểm huấn luyện rất cao (gần 1.0), trong khi điểm kiểm tra tăng dần và tiệm cận mức cao. Có một khoảng cách (gap) giữa hai đường, cho thấy mô hình học rất tốt trên tập train và tổng quát hóa khá tốt trên tập test. Việc sử dụng Ensemble (Rừng) đã giúp kiểm soát variance, tránh bị overfitting nặng như một cây quyết định đơn lẻ.

4.5.4 Kết luận chung

- Bắt đầu với một **mô hình cơ sở (Linear Regression)** để hiểu giới hạn của dữ liệu (là tuyến tính hay không).
- Thử một **mô hình phức tạp hơn (Decision Tree)** để nắm bắt các quy luật phi tuyến tính, chấp nhận rủi ro overfitting.
- Kết thúc bằng một **mô hình Ensemble (Random Forest)** để giữ lại sức mạnh của mô hình phức tạp nhưng loại bỏ overfitting, tạo ra một mô hình cuối cùng mạnh mẽ, chính xác và đáng tin cậy.

5 Giao diện người dùng

Phần này mô tả các thành phần chính của giao diện ứng dụng, bao gồm quá trình tải dữ liệu, khám phá (EDA), tiền xử lý, cấu hình tham số, huấn luyện mô hình và chạy thử dự đoán. Ứng dụng được xây dựng theo dạng Pipeline tuần tự (Step-by-step) giúp người dùng dễ dàng theo dõi luồng xử lý.

5.1 Giao diện tải tập dữ liệu




Figure 5.1.1: Giao diện trước khi tải tập dữ liệu




Figure 5.1.2: Giao diện hiển thị dữ liệu thô và thông tin tổng quan

Sau khi người dùng tải tệp dữ liệu lên (Hình 5.1.2), ứng dụng tự động đọc nội dung và hiển thị 5 dòng đầu tiên của tệp dữ liệu thô ('df.head()'). Đồng thời, kết quả của phương thức .info() cũng được trình bày, giúp người dùng xác minh nhanh tính toàn vẹn, kiểu dữ liệu và số lượng bản ghi.

5.2 Giao diện khám phá dữ liệu (EDA)




Figure 5.2.1: Tab hiển thị Biểu đồ nhiệt tương quan (Heatmap)





Figure 5.2.2: Tab hiển thị Xu hướng doanh số theo thời gian

Tại bước 2, hệ thống cung cấp các biểu đồ trực quan được tổ chức trong các Tabs. Hình 5.2.1 hiển thị ma trận tương quan để đánh giá mối quan hệ giữa các biến số. Hình 5.2.2 hiển thị biểu đồ đường (Line Chart) mô tả xu hướng doanh số theo thời gian, giúp nhận diện tính mùa vụ (seasonality) của dữ liệu.

5.3 Giao diện tiền xử lý dữ liệu

Quy trình tiền xử lý được chia thành các bước nhỏ (3.1 đến 3.4). Tại mỗi bước, hệ thống hiển thị đoạn mã nguồn (Code snippet) thực thi và kết quả dữ liệu tương ứng để đảm bảo tính minh bạch.



Hành động: Thay thế tất cả các giá trị **NaN** trong các cột **Markdown** bằng số **0**.

```
df[markdown_cols] = df[markdown_cols].fillna(0)
```

Kết quả:

	Store	Dept	Date	Weekly_Sales	IsHoliday	Temperature	Fuel_Price	Markdown1	Markdown2	Markdown3	Markdown4	Markdown5	CPI	Unemployment	Type	Si
0	1	1	2010-02-05	24924.5	☐	42.31	2.572	0	0	0	0	0	211.0964	8.106	A	15
1	1	1	2010-02-12	46039.49	☒	38.51	2.548	0	0	0	0	0	211.2422	8.106	A	15
2	1	1	2010-02-19	41595.55	☐	39.93	2.514	0	0	0	0	0	211.2891	8.106	A	15
3	1	1	2010-02-26	19403.54	☐	46.63	2.561	0	0	0	0	0	211.3196	8.106	A	15
4	1	1	2010-03-05	21827.9	☐	46.5	2.625	0	0	0	0	0	211.3501	8.106	A	15

Tiếp tục (Bước 3.2)

Figure 5.3.1: Xử lý dữ liệu khuyết (Missing Values)

Hình 5.3.1 minh họa quá trình xử lý giá trị thiếu cho các cột Markdown, trong đó ứng dụng áp dụng phép `fillna(0)`.




Figure 5.3.2: Tạo đặc trưng mới (Feature Engineering)

Mô-đun tạo đặc trưng (Hình 5.3.2) thực hiện trích xuất thông tin ngày tháng (Year, Month, Week) và mã hóa One-Hot cho biến phân loại 'Type'.




Figure 5.3.3: Chuẩn bị bộ chuẩn hóa (StandardScaler)

Điểm đặc biệt tại Bước 3.4 (Hình 5.3.3): Hệ thống chỉ thực hiện *khởi tạo* bộ chuẩn hóa (StandardScaler). Để tuân thủ nguyên tắc chống rò rỉ dữ liệu (Anti-Data Leakage), việc tính toán tham số (fit) và biến đổi dữ liệu thực tế được hoãn lại cho đến khi dữ liệu được phân chia ở bước tiếp theo.

5.4 Giao diện cấu hình và huấn luyện mô hình




Figure 5.4.1: Chia tập dữ liệu và Cấu hình tham số (Hyperparameters)

Trước khi huấn luyện, giao diện Bước 4 cho phép người dùng:

- Xem thống kê số lượng mẫu sau khi chia tập Train/Test (80/20).
- Tùy chỉnh tham số mô hình:** Người dùng có thể điều chỉnh độ sâu tối đa (`max_depth`) cho Decision Tree hoặc số lượng cây (`n_estimators`) cho Random Forest thông qua các thanh trượt và ô nhập liệu. Tính năng này giúp thực nghiệm ảnh hưởng của siêu tham số đến độ chính xác.




Figure 5.4.2: Kết quả đánh giá mô hình (RMSE và R^2)

Sau khi huấn luyện xong, bảng điều khiển (Dashboard) tại Bước 5 (Hình 5.4.2) hiển thị song song hai chỉ số quan trọng là **RMSE** (Lỗi - càng thấp càng tốt) và R^2 (Độ phù hợp - càng cao càng tốt) cho cả 3 mô hình.




Figure 5.4.3: Biểu đồ phân tán Thực tế vs Dự đoán

Ngoài ra, người dùng có thể chuyển sang Tab "Thực tế vs Dự đoán" và sử dụng hộp chọn (Selectbox) để xem biểu đồ phân tán của từng mô hình cụ thể, giúp đánh giá trực quan mức độ bám sát của dự đoán so với thực tế.

5.5 Giao diện chạy thử mô hình




Figure 5.5.1: Giao diện dự đoán doanh thu tùy chỉnh



Tại bước cuối cùng (Hình 5.5.1), giao diện cung cấp một biểu mẫu nhập liệu trực quan được chia thành 3 nhóm thông tin: Thông tin cửa hàng, Thời gian & Sự kiện, và Chỉ số kinh tế.

- Hỗ trợ chọn ngày tháng cụ thể (Date Picker) để kiểm chứng khả năng dự báo tính thời vụ.
- Tùy chọn ngày lễ (IsHoliday) để xem tác động của các dịp đặc biệt.

Kết quả dự đoán doanh số được hiển thị ngay lập tức sau khi người dùng nhấn nút "Dự đoán".

6 Phân tích và Thảo luận kết quả

Sau khi huấn luyện và đánh giá ba mô hình hồi quy trên cùng một tập dữ liệu kiểm tra (*test set*), chúng ta thu được một cái nhìn rõ ràng về hiệu suất và mức độ phù hợp của từng phương pháp.

6.1 Phân tích ý nghĩa của kết quả

Các kết quả đánh giá không chỉ giúp xác định mô hình nào hoạt động tốt nhất, mà còn củng cố các giả thuyết đã được đưa ra trong giai đoạn Khám phá Dữ liệu (EDA) và Lựa chọn Đặc trưng (Feature Selection).

Hồi quy tuyến tính (*Linear Regression*)

- **Kết quả:** $R^2 = 0.0926$, $RMSE = \$21,752$, $MAE = \$14,561$.
- **Phân tích:** Mô hình chỉ giải thích được 9.26% sự biến động của dữ liệu. Sai số trung bình quá lớn khiến mô hình gần như không có giá trị ứng dụng thực tế.
- **Nguyên nhân:** Các đặc trưng như *Fuel_Price* và *Temperature* có tương quan tuyến tính gần như bằng 0 với *Weekly_Sales*. Do đó, mô hình tuyến tính (chỉ học được mối quan hệ dạng $y = ax + b$) đã không thể nắm bắt được bản chất phi tuyến tính của dữ liệu.

Mô hình Decision Tree và Random Forest

- **Kết quả:** Decision Tree đạt $R^2 = 0.9617$, còn Random Forest đạt $R^2 = 0.9778$.
- **Phân tích:** Hai mô hình dựa trên cây đều cho kết quả vượt trội, chứng minh rằng *Weekly_Sales* là một biến có thể dự đoán được với độ chính xác rất cao.
- **Nguyên nhân:** Không giống như Linear Regression, mô hình cây có thể học các mối quan hệ phức tạp, phi tuyến tính. Các đặc trưng quan trọng nhất được xác định là các yếu tố định danh và phân loại như *Dept*, *Store*, *Size* và *Type*, thay vì các yếu tố kinh tế.

Random Forest vượt trội hơn Decision Tree

- **Kết quả:** Random Forest đạt $RMSE = \$3,404$, giảm 24% so với Decision Tree ($RMSE = \$4,466$).
- **Phân tích:** Mặc dù cả hai đều hiệu quả, Random Forest thể hiện khả năng tổng quát hóa tốt hơn.
- **Nguyên nhân:** Decision Tree đơn lẻ dễ bị *overfitting* (học vẹt). Trong khi đó, Random Forest là mô hình tổ hợp gồm 100 cây, mỗi cây được huấn luyện trên một mẫu con khác nhau của dữ liệu. Kết quả trung bình từ nhiều cây giúp giảm nhiễu và sai lệch, tăng độ ổn định của mô hình.

6.2 Hạn chế của mô hình

Mặc dù Random Forest đạt độ chính xác rất cao ($R^2 = 0.9778$), nó vẫn tồn tại một số hạn chế:

1. **Tính diễn giải (Explainability):** Linear Regression là một mô hình “hộp trắng” (*white-box*) — dễ hiểu và có thể giải thích rõ ràng ảnh hưởng của từng biến. Ngược lại, Random Forest là “hộp đen” (*black-box*), gồm hàng trăm cây phức tạp, rất khó để lý giải một dự đoán cụ thể.
2. **Thời gian huấn luyện:** Random Forest mất **52.86 giây** để huấn luyện, chậm hơn 15 lần so với Decision Tree (3.38 giây) và 440 lần so với Linear Regression (0.12 giây). Khi mở rộng lên các tập dữ liệu lớn (hàng chục triệu dòng), chi phí tính toán là vấn đề đáng kể.
3. **Khả năng dự đoán dữ liệu mới:** Mô hình được huấn luyện trên dữ liệu của 45 cửa hàng và 99 phòng ban, do đó sẽ hoạt động rất chính xác trong phạm vi này. Tuy nhiên, nếu xuất hiện cửa hàng hoặc phòng ban mới, mô hình sẽ không thể dự đoán chính xác.

6.3 Hướng phát triển

Dựa trên kết quả và các hạn chế đã nêu, có thể mở rộng và cải thiện mô hình theo các hướng sau:

- **Tinh chỉnh siêu tham số (Hyperparameter Tuning):** Sử dụng `GridSearchCV` hoặc `RandomizedSearchCV` để tối ưu các tham số như `max_depth` hoặc `min_samples_leaf`, giúp giảm thêm lỗi RMSE và tăng độ chính xác.
- **Thử nghiệm các mô hình Ensemble nâng cao:** Áp dụng các thuật toán như *Gradient Boosting*, *XGBoost* hoặc *LightGBM*, vốn có khả năng học mạnh mẽ hơn nhờ cơ chế huấn luyện tuần tự — mỗi cây mới học để sửa lỗi của cây trước đó.
- **Kỹ thuật tạo đặc trưng (Feature Engineering) nâng cao:**
 - *Đặc trưng dựa trên thời gian (Lag Features):* Ví dụ: `LastWeekSales`, `Avg4WeeksSales`.
 - *Đặc trưng sự kiện (Event-based Features):* Thay vì chỉ dùng `IsHoliday`, có thể tạo thêm biến `DaysUntilNextHoliday` — phản ánh hành vi mua sắm tăng trước kỳ lễ.
- **Triển khai mô hình (Deployment):**
 - Lưu mô hình `RandomForestRegressor` và `StandardScaler` bằng `joblib` hoặc `pickle`.
 - Xây dựng API với `Flask` hoặc `FastAPI` để nhận dữ liệu đầu vào (*JSON*), tải mô hình đã lưu, xử lý và trả về kết quả dự đoán theo thời gian thực.

7 Ràng buộc bổ sung

Mặc dù mô hình *Random Forest* (mô hình tốt nhất của chúng ta) đạt được hiệu suất rất cao ($R^2 = 0.9778$), vẫn còn một phần nhỏ (2.22%) phương sai của `Weekly_Sales` mà mô hình không thể giải thích được. Phần “lỗi” (error) còn lại này không chỉ là nhiễu ngẫu nhiên, mà đại diện cho các yếu tố phức tạp trong thế giới thực mà bộ dữ liệu của chúng ta không ghi lại được. Đây được gọi là các **ràng buộc ngoại sinh** (*external constraints*). Ba trong số các ràng buộc quan trọng nhất bao gồm:

7.1 Đối thủ cạnh tranh

Vấn đề: Mô hình của chúng ta chỉ được huấn luyện trên dữ liệu nội bộ của Walmart (ví dụ: `Store`, `Dept`, `Size`, `Markdown` của Walmart). Nó hoàn toàn “mù” (*blind*) trước các hành động và sự tồn tại của các đối thủ cạnh tranh trong cùng khu vực (như Target, Costco, Kmart).

Cơ chế tác động: Hành vi mua sắm của khách hàng bị ảnh hưởng mạnh mẽ bởi một thị trường cạnh tranh.

Ví dụ (Chiến tranh giá cả): Giả sử mô hình của chúng ta dự đoán doanh số cao cho Tuần 30 tại Cửa hàng 5. Tuy nhiên, cùng tuần đó, một cửa hàng Target ở bên kia đường tung ra chương trình “giảm giá sốc” lớn. Kết quả: Một lượng đáng kể khách hàng chuyển sang mua hàng của Target, khiến doanh số thực tế của Walmart thấp hơn nhiều so với dự đoán.

Tác động đến mô hình: Mô hình không “nhìn thấy” được chương trình giảm giá của Target, nên lỗi này là một *lỗi không thể giải thích được* (unexplained error) do thiếu đặc trưng `Competitor_Activity`.

7.2 Sự kiện bất khả kháng (Thiên nga đen)

Vấn đề: Đây là các thảm họa hiếm gặp, có tác động cực lớn và nằm ngoài mọi dự đoán thông thường (ví dụ: đại dịch, thiên tai quy mô lớn, khủng hoảng tài chính).

Cơ chế tác động: Các sự kiện “Thiên nga đen” phá vỡ hoàn toàn các quy luật lịch sử mà mô hình đã học.

Ví dụ (Đại dịch COVID-19): Mô hình được huấn luyện trên dữ liệu 2010–2012, một giai đoạn “bình thường”. Nó không thể dự đoán được các hành vi phi logic do đại dịch gây ra:

- **Hoảng loạn mua sắm (Panic Buying):** Mô hình dự đoán doanh số tháng 3 (tháng thấp điểm) là \$10,000, nhưng doanh số thực tế vọt lên \$150,000 do người dân tích trữ hàng hóa.
- **Lệnh phong tỏa (Lockdowns):** Mô hình dự đoán doanh số Giáng sinh là \$100,000, nhưng doanh số thực tế là 0 vì cửa hàng buộc phải đóng cửa.

Tác động đến mô hình: Các sự kiện này khiến các dự đoán dựa trên lịch sử trở nên vô nghĩa—vì quan hệ giữa đặc trưng và mục tiêu không còn giữ nguyên.

7.3 Thay đổi về luật/chính sách

Vấn đề: Các mô hình học máy giả định rằng các quy luật của quá khứ sẽ tiếp tục đúng trong tương lai. Tuy nhiên, các thay đổi về luật pháp hoặc chính sách của chính phủ có thể thay đổi các “luật chơi” chỉ sau một đêm.

Cơ chế tác động: Các thay đổi này tạo ra các *điểm gãy cấu trúc* (*structural breaks*) trong dữ liệu.

Ví dụ (Quy định giờ mở cửa): Mô hình được huấn luyện trên dữ liệu 2010–2012, khi cửa hàng mở cửa 7 ngày/tuần. Nó học rằng “Chủ nhật là ngày có doanh số tốt”. Nhưng năm 2013, một luật mới được ban hành, cấm các cửa hàng lớn mở cửa vào Chủ nhật. Kết quả: Mô hình tiếp tục dự đoán doanh số cao cho Chủ nhật, nhưng thực tế là \$0.

Tác động đến mô hình: Sự thay đổi đột ngột về luật (như tăng thuế, thay đổi lương tối thiểu, quy định an toàn sản phẩm) khiến mô hình trở nên “lỗi thời”. Nó cần được *huấn luyện lại* (retrain) với dữ liệu mới để học được “quy tắc bình thường mới”.

8 Tài liệu tham khảo

1. Diebold, F. X. (2015). *Elements of Forecasting (Advanced Version)*. Truy cập tại: <https://www.sas.upenn.edu/~fdiebold/NoHesitations/BookAdvanced.pdf>
2. IBM, *Exploratory Data Analysis (EDA)*. Truy cập tại: <https://www.ibm.com/think/topics/exploratory-data-analysis>
3. Viblo, *Data Visualization với Seaborn*. Truy cập tại: <https://viblo.asia/p/data-visualization-voi-seaborn-o0VlYP9vZ8W>
4. Matplotlib, *Gallery Examples*. Truy cập tại: <https://matplotlib.org/stable/gallery>
5. W3Schools, *Python Pandas Tutorial*. Truy cập tại: <https://www.w3schools.com/python/pandas/default.asp>
6. Scikit-learn, *Machine Learning Library for Python*. Truy cập tại: <https://scikit-learn.org/stable/>
7. Streamlit, *Official Documentation*. Truy cập tại: <https://docs.streamlit.io/>
8. Arun Pandey (2021), *Regression Algorithms Explained*. Truy cập tại: <https://arunp77.medium.com/regression-algorithms-29f112797724>
9. iHOCLAPTRINH, *Machine Learning - Thuật toán StandardScaler*. Truy cập tại: <https://ihoclaptrinh.com/thuan-toan-machine-learning-standardscaler>
10. Scikit-learn, *Model Evaluation Documentation*. Truy cập tại: https://scikit-learn.org/stable/modules/model_evaluation.html
11. Scikit-learn, *Linear Regression Documentation*. Truy cập tại: https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LinearRegression.html
12. Scikit-learn, *Decision Tree Classifier Documentation*. Truy cập tại: <https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeClassifier.html>
13. Scikit-learn, *Random Forest Classifier Documentation*. Truy cập tại: <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>
14. Lex Jansen (2007), *Data Capping and Flooring Approaches*. Truy cập tại: <https://www.lexjansen.com/nesug/nesug07/sa/sa16.pdf> (xem mục 2.1)
15. Scikit-learn, *Preprocessing API*. Truy cập tại: <https://scikit-learn.org/stable/api/sklearn.preprocessing.html>
16. Scikit-learn, *Feature Selection Documentation*. Truy cập tại: https://scikit-learn.org/stable/modules/feature_selection.html
17. Stock, J. H., & Watson, M. W. (2011). *Introduction to Econometrics (3rd Edition)*. Pearson Education. (Tham khảo phần "Linear Regression with Multiple Regressors", Chương 6)
18. Taleb, N. N. (2007). *The Black Swan: The Impact of the Highly Improbable*. Random House.
19. Angrist, J. D., & Pischke, J. S. (2009). *Mostly Harmless Econometrics: An Empiricist's Companion*. Princeton University Press. (Tham khảo phần "Regression Discontinuity Design", Chương 6)



9 Phụ lục

9.1 Mã nguồn

Toàn bộ mã nguồn được lưu ở GitHub:

https://github.com/khoale2k4/data-mining_BTL.git

9.2 Nguồn dữ liệu

Bộ dữ liệu được sử dụng trong dự án được lấy từ Kaggle:

<https://www.kaggle.com/datasets/aslanahmedov/walmart-sales-forecast>